

সিম্পল লিনিয়ার রিগ্রেশন ও গ্র্যাডিয়েন্ট ডিসেন্ট

মেশিন লার্নিং নোটস — সহজ বাংলায় ব্যাখ্যা

১. সিম্পল লিনিয়ার রিগ্রেশন কী?

সিম্পল লিনিয়ার রিগ্রেশন হলো মেশিন লার্নিং-এর সবচেয়ে সহজ ও মৌলিক সুপারভাইজড লার্নিং (Supervised Learning) অ্যালগরিদম, যা রিগ্রেশন (Regression) সমস্যা সমাধানে ব্যবহৃত হয় — অর্থাৎ যখন আমাদের একটি সংখ্যাগত মান (continuous value) প্রেডিক্ট করতে হয়, যেমন বাড়ির দাম, তাপমাত্রা, বা বেতন।

"সিম্পল" শব্দটি এখানে গুরুত্বপূর্ণ — এই অ্যালগরিদমে মাত্র একটি ইনপুট ফিচার (independent variable) ব্যবহার করে একটি আউটপুট (dependent variable) প্রেডিক্ট করা হয়। যেমন — শুধুমাত্র "পড়াশোনার সময়" (একটি ফিচার) দিয়ে "পরীক্ষার নম্বর" (একটি আউটপুট) প্রেডিক্ট করা।

এই অ্যালগরিদমের মূল ধারণা হলো — দুটি ভেরিয়েবলের (ফিচার ও আউটপুট) মধ্যে একটি সরলরৈখিক সম্পর্ক (linear relationship) আছে ধরে নিয়ে, ডেটার মধ্য দিয়ে এমন একটি সরল রেখা (straight line) টানা, যা ডেটা পয়েন্টগুলোর সাথে সবচেয়ে ভালোভাবে মানানসই (best fit)।

২. লিনিয়ার রিগ্রেশনের সমীকরণ

সিম্পল লিনিয়ার রিগ্রেশনের সমীকরণটি দেখতে অনেকটা স্কুলের জ্যামিতিতে পড়া সরলরেখার সমীকরণের মতোই:

$$y = mx + c \quad (\text{অথবা মেশিন লার্নিং-এর ভাষায়: } \hat{y} = w \cdot x + b)$$

- y (বা $\hat{y}$):** আউটপুট বা প্রেডিক্ট করা মান (dependent variable)।
- x:** ইনপুট ফিচার (independent variable)।
- m (বা w — Weight/Coefficient/Slope):** রেখাটির ঢাল — x এক একক বাড়লে y কতটা পরিবর্তিত হবে তা নির্দেশ করে।
- c (বা b — Bias/Intercept):** রেখাটি y-অক্ষকে যেখানে ছেদ করে, অর্থাৎ x = 0 হলে y-এর মান কত হবে।

মডেল ট্রেনিং করার মূল উদ্দেশ্য হলো এমন w (weight) এবং b (bias)-এর সবচেয়ে ভালো মান খুঁজে বের করা, যাতে রেখাটি ডেটা পয়েন্টগুলোর যতটা সম্ভব কাছাকাছি দিয়ে যায়।

৩. "বেস্ট ফিট লাইন" কীভাবে নির্ধারণ করা হয়?

একই ডেটাসেটের মধ্য দিয়ে অসংখ্য রেখা টানা সম্ভব, কিন্তু আমরা এমন একটি রেখা খুঁজি যেটি ডেটা পয়েন্টগুলো থেকে সবচেয়ে কম দূরত্বে অবস্থান করে। এই "দূরত্ব" বা দূরত্ব মাপার জন্য ব্যবহার করা হয় একটি কস্ট ফাংশন (Cost Function)।

৪. কস্ট ফাংশন (Cost Function) — বিস্তারিত

কস্ট ফাংশন হলো এমন একটি গাণিতিক ফাংশন, যা বলে দেয় মডেলের প্রেডিকশন প্রকৃত মান থেকে গড়ে কতটা ভুল (error)। এটি আসলে মডেলের "পারফরম্যান্স মাপার স্কেল" — কস্টের মান যত বেশি, মডেল তত খারাপ প্রেডিক্ট করছে; কস্টের মান যত কম, মডেল তত ভালো। লিনিয়ার রিগ্রেশনে সবচেয়ে বেশি ব্যবহৃত কস্ট ফাংশনটি হলো মিন স্কয়ার্ড এরর (Mean Squared Error / MSE)।

$$J(w, b) = \text{MSE} = (1/n) \times \sum (y_i - \hat{y}_i)^2$$

এখানে —

- J(w, b):** কস্ট ফাংশনের মান, যা w ও b-এর উপর নির্ভরশীল।
- n:** মোট ডেটা পয়েন্টের সংখ্যা।
- y_i:** i-তম ডেটা পয়েন্টের প্রকৃত (actual) মান।
- $\hat{y}_i$:** i-তম ডেটা পয়েন্টের জন্য মডেলের প্রেডিক্ট করা মান ($\hat{y}_i = w \cdot x_i + b$)।

ক) কেন পার্থক্যকে বর্গ (Square) করা হয়?

প্রতিটি ডেটা পয়েন্টের প্রকৃত মান ও প্রেডিক্ট করা মানের পার্থক্যকে ($y_i - \hat{y}_i$) বলা হয় রেসিডুয়াল (Residual) বা ভুল (error)। এই পার্থক্যকে সরাসরি যোগ না করে বর্গ করার পেছনে দুটি কারণ আছে:

- ঋণাত্মক ও ধনাত্মক ভুল বাতিল হওয়া ঠেকানো: কোনো পয়েন্ট ভুল হতে পারে +৫, আবার কোনোটা -৫। সরাসরি যোগ করলে এরা একে অপরকে কাটাকাটি করে ফেলবে এবং মনে হবে মডেলের কোনো ভুল নেই। বর্গ করলে সব মান ধনাত্মক হয়ে যায়, তাই প্রকৃত ভুলের পরিমাণ সঠিকভাবে বোঝা যায়।
- বড় ভুলকে বেশি শাস্তি দেওয়া: বর্গ করার ফলে বড় ভুলগুলো (যেমন ১০) ছোট ভুলের (যেমন ২) তুলনায় অনেক বেশি গুরুত্ব পায় (১০০ বনাম ৪), ফলে মডেল বড় ভুল এড়াতে বেশি সচেষ্ট থাকে।

খ) কস্ট ফাংশনের আকৃতি — কেন এটি একটি "বাটির (bowl)" মতো?

যদি আমরা বিভিন্ন w ও b-এর মানের জন্য J(w, b)-এর মান বসিয়ে একটি ৩-মাত্রিক (3D) গ্রাফ আঁকি, তাহলে সেটি দেখতে অনেকটা একটি উল্টো বাটি বা পেয়ালার (bowl-shaped surface) মতো হয়। এই আকৃতিকে বলা হয় কনভেক্স ফাংশন (Convex Function)।

কনভেক্স আকৃতির সবচেয়ে বড় সুবিধা হলো — এর একটিই গ্লোবাল মিনিমাম (Global Minimum) বা সর্বনিম্ন বিন্দু থাকে, কোনো বিভ্রান্তিকর "লোকাল মিনিমাম" থাকে না। তাই গ্র্যাডিয়েন্ট ডিসেন্ট প্রয়োগ করলে তা সবসময় নিশ্চিতভাবে সঠিক সর্বনিম্ন বিন্দুতেই পৌঁছাবে, ভুল জায়গায় আটকে যাবে না। এই কারণেই সিম্পল লিনিয়ার রিগ্রেশনে গ্র্যাডিয়েন্ট ডিসেন্ট খুব নির্ভরযোগ্যভাবে কাজ করে।

গ) কস্ট ফাংশন ও গ্র্যাডিয়েন্ট ডিসেন্টের সম্পর্ক

কস্ট ফাংশন শুধু "ভুল মাপার" কাজ করে — নিজে থেকে w ও b ঠিক করে না। এই মাপকাঠিকে ব্যবহার করে w ও b -কে ধাপে ধাপে সঠিক দিকে পরিবর্তন করার কাজটিই করে গ্র্যাডিয়েন্ট ডিসেন্ট। সহজ কথায়:

কস্ট ফাংশন বলে দেয় — "আমরা এখন কতটা ভুল করছি?"

গ্র্যাডিয়েন্ট ডিসেন্ট বলে দেয় — "ভুল কমাতে w ও b -কে কোন দিকে, কতটা পরিবর্তন করতে হবে?"

গ্র্যাডিয়েন্ট ডিসেন্ট মূলত কস্ট ফাংশনের গ্র্যাডিয়েন্ট বা ঢাল (derivative/slope) হিসাব করে বোঝে বাটি-আকৃতির পৃষ্ঠতলের কোন দিকে নিচের দিকে নামা যাবে, এবং সেই দিকে w ও b -কে সামান্য পরিবর্তন করে। এভাবে বারবার পুনরাবৃত্তি করে একসময় $J(w, b)$ -এর মান সর্বনিম্ন (bowl-এর একদম তলদেশে) পৌঁছে যায় — এবং তখনকার w ও b -ই হয় মডেলের সবচেয়ে ভালো (optimal) মান।

লক্ষ্য একটাই — কস্ট ফাংশন $J(w, b)$ -এর মান সবচেয়ে কম করে এমন w ও b খুঁজে বের করা। কস্ট যত কম, রেখাটি ডেটার সাথে তত ভালোভাবে খাপ খায় (best fit)।

৫. গ্র্যাডিয়েন্ট ডিসেন্ট (Gradient Descent) কী?

এখন প্রশ্ন হলো — সবচেয়ে ভালো w ও b কীভাবে খুঁজে পাওয়া যায়? এর জন্যই ব্যবহার করা হয় গ্র্যাডিয়েন্ট ডিসেন্ট — একটি অপটিমাইজেশন (optimization) অ্যালগরিদম, যা ধাপে ধাপে w ও b -এর মান পরিবর্তন করে কস্ট ফাংশনের (MSE) মান ধীরে ধীরে কমিয়ে আনে, যতক্ষণ না এটি সর্বনিম্ন (minimum) মানে পৌঁছায়।

সহজ উপমা: কল্পনা করুন, আপনি ঘন কুয়াশায় ঢাকা একটি পাহাড়ের উপরে দাঁড়িয়ে আছেন এবং সবচেয়ে নিচু জায়গায় (উপত্যকায়) পৌঁছাতে চান, কিন্তু আশেপাশে কিছুই দেখতে পাচ্ছেন না। তখন স্বাভাবিক উপায় হলো — পায়ের নিচের মাটি অনুভব করে বোঝা, কোন দিকে ঢাল সবচেয়ে খাড়া নিচের দিকে নামছে, এবং সেই দিকে ছোট ছোট পা ফেলে এগিয়ে যাওয়া। এভাবে ধাপে ধাপে এগোতে এগোতে একসময় সবচেয়ে নিচু স্থানে (সর্বনিম্ন কস্ট) পৌঁছে যাওয়া যায়। গ্র্যাডিয়েন্ট ডিসেন্ট ঠিক এভাবেই কাজ করে।

গ্র্যাডিয়েন্ট ডিসেন্ট কীভাবে কাজ করে? (ধাপে ধাপে)

- শুরু করা: w ও b -এর মান এলোমেলোভাবে (random) বা শূন্য দিয়ে শুরু করা হয়।
- গ্র্যাডিয়েন্ট (Gradient) বের করা: বর্তমান w ও b -এর মানে কস্ট ফাংশনের ঢাল (slope) বা গ্র্যাডিয়েন্ট হিসাব করা হয় — অর্থাৎ, w বা b সামান্য পরিবর্তন করলে কস্ট কতটা ও কোন দিকে পরিবর্তিত হবে তা বের করা হয় (এটি ক্যালকুলাসের ডেরিভেটিভ/Derivative ব্যবহার করে করা হয়)।
- বিপরীত দিকে এগোনো: গ্র্যাডিয়েন্ট যে দিকে কস্ট বাড়ায়, তার ঠিক বিপরীত দিকে w ও b -এর মান একটু একটু করে পরিবর্তন (update) করা হয়, যাতে কস্ট কমে।
- পুনরাবৃত্তি (Repeat): এই প্রক্রিয়া বহুবার (অনেকগুলো iteration বা epoch ধরে) চালানো হয়, যতক্ষণ না কস্ট ফাংশনের মান আর তেমন কমছে না — অর্থাৎ মডেল সর্বনিম্ন (minimum) বিন্দুর কাছাকাছি পৌঁছে গেছে।

ওজন আপডেট করার সূত্র (Update Rule)

$$w = w - \alpha \times (\partial \text{Cost} / \partial w)$$

$$b = b - \alpha \times (\partial \text{Cost} / \partial b)$$

এখানে α (আলফা) হলো লার্নিং রেট (Learning Rate) — এটি নির্ধারণ করে প্রতিটি ধাপে w ও b কতটা পরিমাণ পরিবর্তিত হবে। আর $(\partial \text{Cost} / \partial w)$ অংশটি হলো গ্র্যাডিয়েন্ট, যা নির্দেশ করে কোন দিকে ও কতটা পরিবর্তন করলে কস্ট কমেবে।

৬. লার্নিং রেট (Learning Rate) কেন গুরুত্বপূর্ণ?

লার্নিং রেট (α) হলো গ্র্যাডিয়েন্ট ডিসেন্টের সবচেয়ে গুরুত্বপূর্ণ হাইপারপ্যারামিটার (hyperparameter)। এটি ঠিক করে প্রতিটি ধাপে আমরা কত বড় "পা" ফেলে এগোবো।

লার্নিং রেট	প্রভাব	সমস্যা
খুব ছোট (Too Small)	খুব ধীরে ধীরে minimum-এর দিকে এগোয়	ট্রেনিং করতে অনেক বেশি সময় ও ধাপ লাগে
উপযুক্ত (Optimal)	যুক্তিসঙ্গত সময়ে সঠিকভাবে minimum-এ পৌঁছায়	সবচেয়ে ভালো ফলাফল
খুব বড় (Too Large)	minimum বিন্দু ডিঙিয়ে (overshoot) বারবার এদিক-ওদিক লাফাতে থাকে	কস্ট কমার বদলে বাড়তে পারে, মডেল কখনোই সঠিক মানে পৌঁছায় না (diverge করে)

৭. গ্র্যাডিয়েন্ট ডিসেন্টের ধরন (Types)

- ব্যাচ গ্র্যাডিয়েন্ট ডিসেন্ট (Batch Gradient Descent): প্রতিটি ধাপে w ও b আপডেট করার আগে সম্পূর্ণ ট্রেনিং ডেটাসেট ব্যবহার করে গ্র্যাডিয়েন্ট হিসাব করা হয়। এটি স্থিতিশীল

(stable) কিন্তু বড় ডেটাসেটে ধীরগতির।

- স্টোকাস্টিক গ্র্যাডিয়েন্ট ডিসেন্ট (Stochastic Gradient Descent / SGD): প্রতিটি ধাপে মাত্র একটি এলোমেলো ডেটা পয়েন্ট ব্যবহার করে গ্র্যাডিয়েন্ট হিসাব করা হয়। এটি দ্রুত কিন্তু কম স্থিতিশীল (noisy)।
- মিনি-ব্যাচ গ্র্যাডিয়েন্ট ডিসেন্ট (Mini-batch Gradient Descent): সম্পূর্ণ ডেটাসেট ও একক ডেটা পয়েন্টের মাঝামাঝি একটি ছোট অংশ (batch, যেমন ৩২ বা ৬৪টি ডেটা) ব্যবহার করা হয়। এটি বাস্তবে সবচেয়ে বেশি ব্যবহৃত পদ্ধতি, কারণ এটি গতি ও স্থিতিশীলতার মধ্যে ভারসাম্য রক্ষা করে।

সংক্ষিপ্ত উদাহরণ: ধরা যাক, আমরা "ঘরের আয়তন" (x) দিয়ে "ঘরের দাম" (y) প্রেডিক্ট করতে চাই। প্রথমে w ও b -কে এলোমেলোভাবে বসানো হবে, যা দিয়ে একটি ভুল রেখা তৈরি হবে। তারপর গ্র্যাডিয়েন্ট ডিসেন্ট বারবার w ও b -কে ছোট ছোট ধাপে পরিবর্তন করতে থাকবে, যতক্ষণ না রেখাটি ডেটা পয়েন্টগুলোর সাথে সবচেয়ে ভালোভাবে মানিয়ে যায় — অর্থাৎ MSE সবচেয়ে কম হয়।

৮. সিম্পল লিনিয়ার রিগ্রেশনের সুবিধা (Advantages)

- ✓ সহজ ও দ্রুত বোঝা যায়:
এটি মেশিন লার্নিং-এর সবচেয়ে সহজ অ্যালগরিদমগুলোর একটি, শেখা ও বাস্তবায়ন করা সহজ।
- ✓ ব্যাখ্যাযোগ্য (Interpretable):
রেখার ঢাল (w) দেখেই বোঝা যায় ইনপুট ও আউটপুটের মধ্যে সম্পর্ক কেমন।
- ✓ কম গণনার খরচ:
মডেল ট্রেনিং করতে তুলনামূলক কম কম্পিউটেশনাল রিসোর্স লাগে।
- ✓ বেসলাইন মডেল হিসেবে চমৎকার:
যেকোনো রিগ্রেশন সমস্যা শুরু করার আগে একটি সহজ তুলনামূলক মডেল হিসেবে ব্যবহার করা যায়।

৯. সিম্পল লিনিয়ার রিগ্রেশনের অসুবিধা (Disadvantages)

- ✗ শুধু একটি ফিচার ব্যবহার করে:
বাস্তব সমস্যায় সাধারণত একাধিক বিষয় ফলাফলকে প্রভাবিত করে, যা এই মডেল ধরতে পারে না।
- ✗ শুধু সরলরৈখিক সম্পর্ক ধরতে পারে:
ডেটার মধ্যে সম্পর্ক যদি বাঁকা (non-linear) হয়, তাহলে এই মডেল ভালো ফলাফল দিতে পারে না।
- ✗ আউটলিয়ারের প্রতি সংবেদনশীল:
ডেটাসেটে ব্যতিক্রমী মান (outlier) থাকলে বেস্ট ফিট লাইন সহজেই ভুল দিকে বেঁকে যেতে পারে।

১০. গ্র্যাডিয়েন্ট ডিসেন্টের সুবিধা ও অসুবিধা

- ✓ যেকোনো আকারের ডেটাসেটে কাজ করে:
ডেটাসেট অনেক বড় হলেও (বিশেষত মিনি-ব্যাচ পদ্ধতিতে) কার্যকরভাবে ব্যবহার করা যায়।
- ✓ বহুমুখী ব্যবহার:
শুধু লিনিয়ার রিগ্রেশন নয়, প্রায় সব মেশিন লার্নিং ও ডিপ লার্নিং মডেল ট্রেনিং করতে এই একই মূলনীতি ব্যবহৃত হয়।
- ✗ লার্নিং রেটের উপর নির্ভরশীল:
ভুল লার্নিং রেট বেছে নিলে মডেল সঠিকভাবে ট্রেনিং নাও হতে পারে।
- ✗ লোকাল মিনিমামে আটকে যাওয়ার ঝুঁকি:
জটিল (non-convex) কস্ট ফাংশনে গ্র্যাডিয়েন্ট ডিসেন্ট কখনো কখনো প্রকৃত সর্বনিম্ন বিন্দুর বদলে একটি স্থানীয় সর্বনিম্ন (local minimum) বিন্দুতে আটকে যেতে পারে।

১১. বাস্তব জীবনে ব্যবহার (Use Cases)

- রিয়েল এস্টেট: ঘরের আয়তনের ভিত্তিতে দাম অনুমান করা।
- বিক্রয় পূর্বাভাস: বিজ্ঞাপনে খরচের ভিত্তিতে বিক্রয়ের পরিমাণ প্রেডিক্ট করা।
- শিক্ষা: পড়াশোনার সময়ের ভিত্তিতে পরীক্ষার ফলাফল অনুমান করা।
- আবহাওয়া পূর্বাভাস: একটি নির্দিষ্ট ফ্যাক্টরের (যেমন সময়) ভিত্তিতে তাপমাত্রার প্রবণতা বোঝা।
- গ্র্যাডিয়েন্ট ডিসেন্টের ব্যবহার: শুধু লিনিয়ার রিগ্রেশন নয়, লজিস্টিক রিগ্রেশন, নিউরাল নেটওয়ার্ক ও প্রায় সব আধুনিক ডিপ লার্নিং মডেল ট্রেনিং করার মূল ভিত্তি এই গ্র্যাডিয়েন্ট ডিসেন্ট।

১২. সংক্ষিপ্ত সারাংশ (Summary)

- সিম্পল লিনিয়ার রিগ্রেশন একটি মাত্র ইনপুট ফিচার ব্যবহার করে একটি সরল রেখার ($y = wx + b$) মাধ্যমে সংখ্যাগত মান প্রেডিক্ট করে।
- মডেলের "ভুল" মাপা হয় Mean Squared Error (MSE) দিয়ে — যা যত কম, রেখা তত ভালো ফিট করে।
- গ্র্যাডিয়েন্ট ডিসেন্ট হলো সেই অপটিমাইজেশন পদ্ধতি, যা ধাপে ধাপে w ও b পরিবর্তন করে MSE-কে সর্বনিম্ন করে।
- লার্নিং রেট (α) সঠিকভাবে বেছে নেওয়া অত্যন্ত জরুরি — খুব ছোট হলে ট্রেনিং ধীর হয়, খুব বড় হলে মডেল সঠিক মানে পৌঁছাতে ব্যর্থ হয়।

- ব্যাচ, স্টোকাস্টিক (SGD), ও মিনি-ব্যাচ — এই তিন ধরনের গ্র্যাডিয়েন্ট ডিসেন্ট বাস্তবে ব্যবহৃত হয়, যার মধ্যে মিনি-ব্যাচ সবচেয়ে জনপ্রিয়।