

লজিস্টিক রিগ্রেশন (Logistic Regression)

মেশিন লার্নিং নোটস — সহজ বাংলায় ব্যাখ্যা

১. লজিস্টিক রিগ্রেশন কী?

নামে "রিগ্রেশন" থাকলেও লজিস্টিক রিগ্রেশন আসলে মেশিন লার্নিং-এর একটি সুপারভাইজড লার্নিং (Supervised Learning) অ্যালগরিদম, যা মূলত ক্লাসিফিকেশন (Classification) সমস্যা সমাধানের জন্য ব্যবহৃত হয় — সংখ্যা প্রেডিক্ট করার জন্য নয়। এটি দিয়ে সাধারণত দুটি ক্যাটাগরির (Binary Classification) মধ্যে সিদ্ধান্ত নেওয়া হয়, যেমন — "হ্যাঁ/না", "স্প্যাম/স্প্যাম নয়", "পাশ/ফেল", "রোগ আছে/নেই" ইত্যাদি।

সহজ ভাষায় বলতে গেলে, লজিস্টিক রিগ্রেশন একটি ইনপুট ডেটা দেখে বলে দেয় — এই ডেটাটি একটি নির্দিষ্ট ক্লাসের (যেমন "হ্যাঁ") হওয়ার সম্ভাবনা (probability) কত। এই সম্ভাবনা যদি একটি নির্দিষ্ট সীমার (threshold, সাধারণত ০.৫) চেয়ে বেশি হয়, তাহলে সেটিকে এক ক্লাসে ফেলা হয়, কম হলে অন্য ক্লাসে।

২. লিনিয়ার রিগ্রেশনের সাথে পার্থক্য

লিনিয়ার রিগ্রেশন একটি সরলরেখিক (straight line) সম্পর্কের মাধ্যমে সংখ্যাগত মান (continuous value) প্রেডিক্ট করে — যার ফলাফল হতে পারে যেকোনো সংখ্যা ($-\infty$ থেকে $+\infty$)। কিন্তু ক্লাসিফিকেশন সমস্যায় আমাদের দরকার একটি সম্ভাবনা, যার মান সবসময় ০ থেকে ১-এর মধ্যে থাকতে হবে। এই কাজটি করার জন্য লজিস্টিক রিগ্রেশন একটি বিশেষ ফাংশন ব্যবহার করে, যাকে বলা হয় সিগময়েড ফাংশন (Sigmoid Function)।

৩. সিগময়েড ফাংশন (Sigmoid Function)

সিগময়েড ফাংশন (যাকে লজিস্টিক ফাংশন-ও বলা হয়) যেকোনো সংখ্যাকে ($-\infty$ থেকে $+\infty$) নিয়ে তাকে ০ থেকে ১-এর মধ্যে একটি মানে রূপান্তরিত করে। এই ফাংশনের গ্রাফ দেখতে ইংরেজি "S" অক্ষরের মতো, তাই একে "S-আকৃতির বক্ররেখা (S-curve)"-ও বলা হয়।

$$\sigma(z) = 1 / (1 + e^{-z})$$

এখানে z হলো লিনিয়ার রিগ্রেশনের মতোই একটি সমীকরণ ($z = w_1x_1 + w_2x_2 + \dots + b$), অর্থাৎ ফিচারগুলোর ওজনযুক্ত যোগফল। এই z -কে সিগময়েড ফাংশনে বসালে একটি সম্ভাবনা (probability) পাওয়া যায়, যা সবসময় ০ ও ১-এর মধ্যে থাকে।

বোঝার সহজ উপায়: z -এর মান যত বড় (ধনাত্মক) হবে, সম্ভাবনা তত ১-এর কাছাকাছি যাবে। z -এর মান যত ছোট (ঋণাত্মক) হবে, সম্ভাবনা তত ০-এর কাছাকাছি যাবে। আর $z = 0$ হলে সম্ভাবনা হবে ঠিক ০.৫।

৪. লজিস্টিক রিগ্রেশন কীভাবে কাজ করে?

- ইনপুট ফিচার নেওয়া: ডেটাসেটের প্রতিটি ফিচার ($x_1, x_2, x_3, \dots$) নেওয়া হয়।
- লিনিয়ার সমীকরণ তৈরি: প্রতিটি ফিচারকে একটি ওজন (weight) দিয়ে গুণ করে যোগ করা হয়, সাথে একটি ব্যাস (bias) যোগ করা হয় — এভাবে z বের করা হয়।
- সিগময়েড ফাংশনে পাঠানো: z -কে সিগময়েড ফাংশনে দিয়ে একটি সম্ভাবনা (০ থেকে ১-এর মধ্যে) বের করা হয়।
- থ্রেশহোল্ড (Threshold) দিয়ে সিদ্ধান্ত নেওয়া: সম্ভাবনা যদি ০.৫-এর বেশি হয়, তাহলে ক্লাস "১" (যেমন "হ্যাঁ"), আর কম হলে ক্লাস "০" (যেমন "না") ধরা হয়।
- মডেল ট্রেনিং (ওজন ঠিক করা): শুরুতে ওজনগুলো (weights) এলোমেলোভাবে বসানো হয়, তারপর কস্ট ফাংশন (Cost Function) মিনিমাইজ করার মাধ্যমে ধীরে ধীরে সঠিক ওজন বের করা হয়, যাতে প্রেডিকশন যতটা সম্ভব সঠিক হয়।

উদাহরণ: ধরা যাক, আমরা একজন শিক্ষার্থী পরীক্ষায় পাশ করবে কিনা তা তার পড়ার সময় (study hours) দেখে প্রেডিক্ট করতে চাই।

মডেল প্রথমে study hours-কে একটি সমীকরণে বসিয়ে z বের করবে, তারপর সিগময়েড ফাংশন দিয়ে একটি সম্ভাবনা বের করবে — ধরা যাক তা হলো ০.৮২। যেহেতু ০.৮২ > ০.৫, তাই মডেল প্রেডিক্ট করবে যে শিক্ষার্থীটি "পাশ" করবে।

৫. কস্ট ফাংশন (Cost Function)

লিনিয়ার রিগ্রেশনে যেমন "Mean Squared Error" ব্যবহার করা হয়, লজিস্টিক রিগ্রেশনে তেমন ব্যবহার করা হয় লগ লস (Log Loss) বা ক্রস-এন্ট্রপি লস (Cross-Entropy Loss)। এটি মূলত মাপে যে, মডেলের প্রেডিক্ট করা সম্ভাবনা প্রকৃত ফলাফল থেকে কতটা দূরে। এই ফাংশনের মান যত কম হবে, মডেল তত ভালো কাজ করছে বলে ধরা হয়। গ্র্যাডিয়েন্ট ডিসেন্ট (Gradient Descent) নামক একটি পদ্ধতি ব্যবহার করে ধাপে ধাপে ওজনগুলো পরিবর্তন করে এই কস্ট ফাংশনের মান সবচেয়ে কম করা হয়।

৬. ডিসিশন বাউন্ডারি (Decision Boundary)

লজিস্টিক রিগ্রেশন মূলত একটি সরলরেখিক সীমানা (linear boundary) তৈরি করে, যা ডেটাকে দুটি ক্লাসে ভাগ করে। এই সীমানাকেই বলা হয় ডিসিশন বাউন্ডারি। দুটি ফিচারের ক্ষেত্রে এই সীমানা দেখতে একটি সরল রেখার মতো, আর বেশি ফিচার থাকলে এটি একটি প্লেন বা হাইপারপ্লেন (hyperplane) হয়।

৭. মাল্টি-ক্লাস ক্লাসিফিকেশন

লজিস্টিক রিগ্রেশন মূলত দুই ক্লাসের (Binary) সমস্যার জন্য তৈরি হলেও, দুইয়ের বেশি ক্লাসের সমস্যায়ও এটি ব্যবহার করা যায় নিচের দুটি পদ্ধতিতে:

- ওয়ান-ভার্সেস-রেস্ট (One-vs-Rest / OvR): প্রতিটি ক্লাসের জন্য আলাদা আলাদা বাইনারি মডেল তৈরি করা হয় (যেমন "ক্লাস A বনাম বাকি সব")।
- সফটম্যাক্স রিগ্রেশন (Softmax Regression / Multinomial): সিগময়েড ফাংশনের বদলে সফটম্যাক্স ফাংশন ব্যবহার করে একসাথে সব ক্লাসের সম্ভাবনা বের করা হয়।

৮. লজিস্টিক রিগ্রেশনের সুবিধা (Advantages)

- ✓ সহজ ও দ্রুত: অ্যালগরিদমটি বোঝা এবং প্রয়োগ করা তুলনামূলক সহজ, এবং প্রশিক্ষণে কম্পিউটেশনাল খরচও কম।
- ✓ ব্যাখ্যাত্মক (Interpretable): প্রতিটি ফিচারের ওজন (coefficient) দেখে বোঝা যায় সেই ফিচারটি ফলাফলের উপর কতটা এবং কোন দিকে প্রভাব ফেলছে।
- ✓ সম্ভাবনা প্রদান করে: শুধু ক্লাস বলে না, বরং একটি সম্ভাবনার মান দেয়, যা অনেক ক্ষেত্রে বেশি কার্যকর।
- ✓ ওভারফিটিং কম হয়: সরল মডেল হওয়ায়, বিশেষ করে ছোট ডেটাসেটে, এটি ওভারফিটিং-এর ঝুঁকি কম থাকে (রেগুলারাইজেশন ব্যবহার করলে আরও কম হয়)।
- ✓ বেসলাইন মডেল হিসেবে চমৎকার: যেকোনো ক্লাসিফিকেশন সমস্যা গুরুত্রে একটি সহজ ও নির্ভরযোগ্য বেসলাইন মডেল হিসেবে ব্যবহার করা যায়।

৯. লজিস্টিক রিগ্রেশনের অসুবিধা (Disadvantages)

- ✗ শুধু সরলরৈখিক সীমানা তৈরি করে: ডেটা যদি নন-লিনিয়ারভাবে বিভক্ত হয় (জটিল প্যাটার্ন থাকে), তাহলে লজিস্টিক রিগ্রেশন ভালো ফলাফল দিতে পারে না।
- ✗ আউটলিয়ারের প্রতি সংবেদনশীল: ডেটাসেটে ব্যতিক্রমী মান (outlier) থাকলে মডেলের ফলাফল প্রভাবিত হতে পারে।
- ✗ ফিচারগুলোর মধ্যে মাল্টিকলিনিয়ারিটি সমস্যা তৈরি করে: ইনপুট ফিচারগুলো একে অপরের সাথে অতিরিক্ত সম্পর্কযুক্ত (correlated) হলে মডেলের কার্যকারিতা কমে যায়।
- ✗ বড় ও জটিল ডেটাসেটে কম কার্যকর: বেশি ফিচার ও জটিল সম্পর্কযুক্ত ডেটায় Random Forest বা Neural Network-এর তুলনায় কম নির্ভুলতা দেয়।
- ✗ পর্যাপ্ত ডেটা প্রয়োজন: নির্ভরযোগ্য ফলাফলের জন্য প্রতিটি ক্লাসে যথেষ্ট পরিমাণ ডেটা থাকা দরকার, নাহলে মডেল ভালোভাবে শিখতে পারে না।

১০. লিনিয়ার বনাম লজিস্টিক রিগ্রেশন

বিষয়	লিনিয়ার রিগ্রেশন	লজিস্টিক রিগ্রেশন
ব্যবহার	রিগ্রেশন (সংখ্যা প্রেডিকশন)	ক্লাসিফিকেশন (ক্যাটাগরি প্রেডিকশন)
আউটপুট	যেকোনো সংখ্যা ($-\infty$ থেকে $+\infty$)	সম্ভাবনা (০ থেকে ১)
ফাংশন	সরলরৈখিক সমীকরণ	সিগময়েড ফাংশন
কস্ট ফাংশন	Mean Squared Error	Log Loss / Cross-Entropy
গ্রাফের আকৃতি	সরল রেখা	S-আকৃতির বক্ররেখা

১১. বাস্তব জীবনে ব্যবহার (Use Cases)

- স্প্যাম ইমেইল শনাক্তকরণ: কোনো ইমেইল স্প্যাম নাকি সাধারণ, তা নির্ধারণ করা।
- মেডিকেল ডায়াগনসিস: রোগীর বিভিন্ন উপসর্গ ও পরীক্ষার ফলাফল দেখে কোনো রোগ আছে কিনা তা প্রেডিক্ট করা (যেমন ডায়াবেটিস, হৃদরোগ)।
- কাস্টমার চার্ন প্রেডিকশন: কোনো গ্রাহক সেবা ছেড়ে চলে যাবে কিনা তা অনুমান করা।
- ক্রেডিট রিস্ক বিশ্লেষণ: কোনো ঋণগ্রহীতা ঋণ পরিশোধ করতে পারবে কিনা তা নির্ধারণ করা (ব্যাংকিং সেক্টরে ব্যাপকভাবে ব্যবহৃত)।
- মার্কেটিং: কোনো গ্রাহক একটি বিজ্ঞাপনে ক্লিক করবে বা পণ্য কিনবে কিনা তা প্রেডিক্ট করা।

১২. সংক্ষিপ্ত সারাংশ (Summary)

- লজিস্টিক রিগ্রেশন মূলত একটি ক্লাসিফিকেশন অ্যালগরিদম, যদিও নামে "রিগ্রেশন" আছে।

- এটি সিগময়েড ফাংশন ব্যবহার করে যেকোনো মানকে ০ থেকে ১-এর মধ্যে সম্ভাবনায় রূপান্তরিত করে।
- থ্রেশহোল্ড (সাধারণত ০.৫) ব্যবহার করে সেই সম্ভাবনা থেকে চূড়ান্ত ক্লাস নির্ধারণ করা হয়।
- মডেল ট্রেনিং হয় ক্রস্ট ফাংশন (Log Loss) মিনিমাইজ করার মাধ্যমে, গ্র্যাডিয়েন্ট ডিসেন্ট পদ্ধতিতে।
- এটি সহজ, দ্রুত ও ব্যাখ্যাযোগ্য হওয়ায় বাইনারি ক্লাসিফিকেশন সমস্যায় একটি চমৎকার বেসলাইন মডেল হিসেবে ব্যাপকভাবে ব্যবহৃত হয়।